

POSTECH • TECH CHALLENGE • FASE 2

Classificando a Qualidade de Vinhos com Machine Learning

Uma leitura orientada a dados sobre o que separa um vinho premiado de um vinho comum — e como a produção pode usar isso a seu favor.

Apresentação Executiva — Análise Exploratória & Modelos Preditivos

Avaliar qualidade hoje depende de degustação humana

01

Subjetivo

A nota final varia conforme o avaliador, o dia e até o paladar de quem prova.

02

Lento

Análise sensorial não escala: cada lote depende de tempo de especialistas.

03

Tardio

O problema só é percebido depois que o vinho já está pronto — tarde para corrigir o processo.

Nosso objetivo

Usar as características físico-químicas medidas em laboratório — acidez, açúcar, álcool, sulfatos — para prever se um vinho será de Alta Qualidade antes mesmo da degustação final.

1.143 amostras de vinho tinto, medidas em laboratório

1.143

amostras analisadas

11

variáveis físico-químicas

0

valores em branco

13,9%

são vinhos de alta qualidade

O que foi medido em cada amostra

Acidez fixa e volátil

Ácido cítrico

Açúcar residual

Cloretos

Dióxido de enxofre livre e total

Densidade

pH

Sulfatos

Teor alcoólico


Fonte: Wine Quality Dataset (Kaggle) — variante tinta do "Vinho Verde" português

PRIMEIRO INSIGHT


Vinhos premiados são raros — e isso muda como olhamos para o problema

Apenas 159 das 1.143 amostras (13,9%) atingiram nota 7 ou mais. Isso significa que um modelo ingênuo, que sempre "apostasse" em qualidade baixa/média, já acertaria 86% das vezes — sem identificar nenhum vinho bom.

Por isso, avaliamos os modelos além da simples "taxa de acerto" — priorizando métricas que enxergam especificamente a capacidade de identificar corretamente os vinhos de alta qualidade.



Dois fatores se destacam acima de todos os outros



Comparação da distribuição de cada variável entre vinhos de baixa/média e de alta qualidade

↑ Teor alcoólico

Vinhos de alta qualidade têm, em média, mais álcool — reflexo de uvas colhidas em ponto de maturação mais avançado.

↓ Acidez volátil


Quanto maior a acidez volátil, pior a nota — esse composto está ligado ao defeito sensorial de "gosto de vinagre".

Como as variáveis se relacionam entre si e com a qualidade

Leitura executiva

Variáveis em vermelho tendem a acompanhar a qualidade; em azul, tendem a se opor a ela. Quanto mais forte a cor, mais forte a relação.

Algumas variáveis físico-químicas também se movem juntas — por exemplo, acidez fixa e ácido cítrico — o que é esperado quimicamente e foi considerado na escolha dos modelos.



Base de dados limpa, sem informações faltantes

- **Sem valores em branco**

Todas as 1.143 amostras têm as 11 variáveis completas — não foi necessária nenhuma imputação de dados.

- **Amostras repetidas foram mantidas**

125 amostras com medições idênticas foram preservadas: refletem limitação de precisão do instrumento, não erro de coleta, e representam vinhos de fato diferentes.

- **Valores extremos foram ajustados, não descartados**

Variáveis como açúcar residual e cloretos apresentam amostras bem acima da média. Em vez de excluir essas linhas — o que reduziria ainda mais os já raros vinhos de alta qualidade — os valores extremos foram limitados a uma faixa razoável, preservando o volume de dados.

Treinamos e comparamos dois modelos preditivos

Random Forest


Combina centenas de "árvores de decisão" para votar na previsão final. Lida bem com relações complexas entre variáveis.

SVM (Máquina de Vetores de Suporte)

Busca a fronteira mais clara possível entre vinhos bons e vinhos médios/ruins, com boa capacidade de capturar padrões não lineares.

RESULTADO DA COMPARAÇÃO

Random Forest foi o modelo mais preciso e mais consistente




89,5%

de acerto geral com o Random Forest — e a maior taxa de identificação correta dos vinhos de alta qualidade entre os dois modelos.

Por que confiar nesse resultado?

O modelo foi testado em 5 recortes diferentes dos dados (validação cruzada) e manteve desempenho estável em todos eles — não foi um resultado de sorte em um único teste.



O modelo é mais forte confirmando vinhos bons do que capturando todos eles



		Random Forest		SVM (RBF)	
Real	Baixa/Média	185	12	186	11
	Alta	12	20	14	18
		Predito		Predito	
		Baixa/Média	Alta	Baixa/Média	Alta

Em cada 10 vinhos que o modelo aponta como "alta qualidade", cerca de 6 realmente são. Ele erra mais ao deixar passar despercebidos alguns vinhos bons do que ao classificar um vinho comum como excelente.

As mesmas duas variáveis lideram nos dois modelos



Implicação para a produção

Controlar o ponto de colheita (teor alcoólico) e o processo de fermentação (acidez volátil) são as duas alavancas com maior potencial de impacto na qualidade final — mais do que qualquer ajuste isolado de conservantes ou açúcar.

Como usar esse modelo na prática

01

Triagem antecipada

Usar o modelo para sinalizar lotes com maior probabilidade de qualidade baixa antes da degustação final, priorizando o tempo dos enólogos.

02

Foco operacional

Direcionar esforços de controle de processo para teor alcoólico (ponto de colheita) e acidez volátil (controle de fermentação).

03

Mais dados, mais confiança

Ampliar a coleta de amostras de vinhos de alta qualidade (hoje só 14% da base) para melhorar a capacidade do modelo de não deixar nenhum vinho bom passar despercebido.

Obrigado

Dados físico-químicos já carregam boa parte do sinal sobre a qualidade de um vinho — e um modelo bem calibrado pode antecipar decisões que hoje só a degustação final revela.

Detalhes técnicos completos disponíveis no notebook e repositório do projeto.